



大数据导论

Introduction to Big Data



大数据回归预测：基础概念与算法

叶允明

计算机科学与技术学院

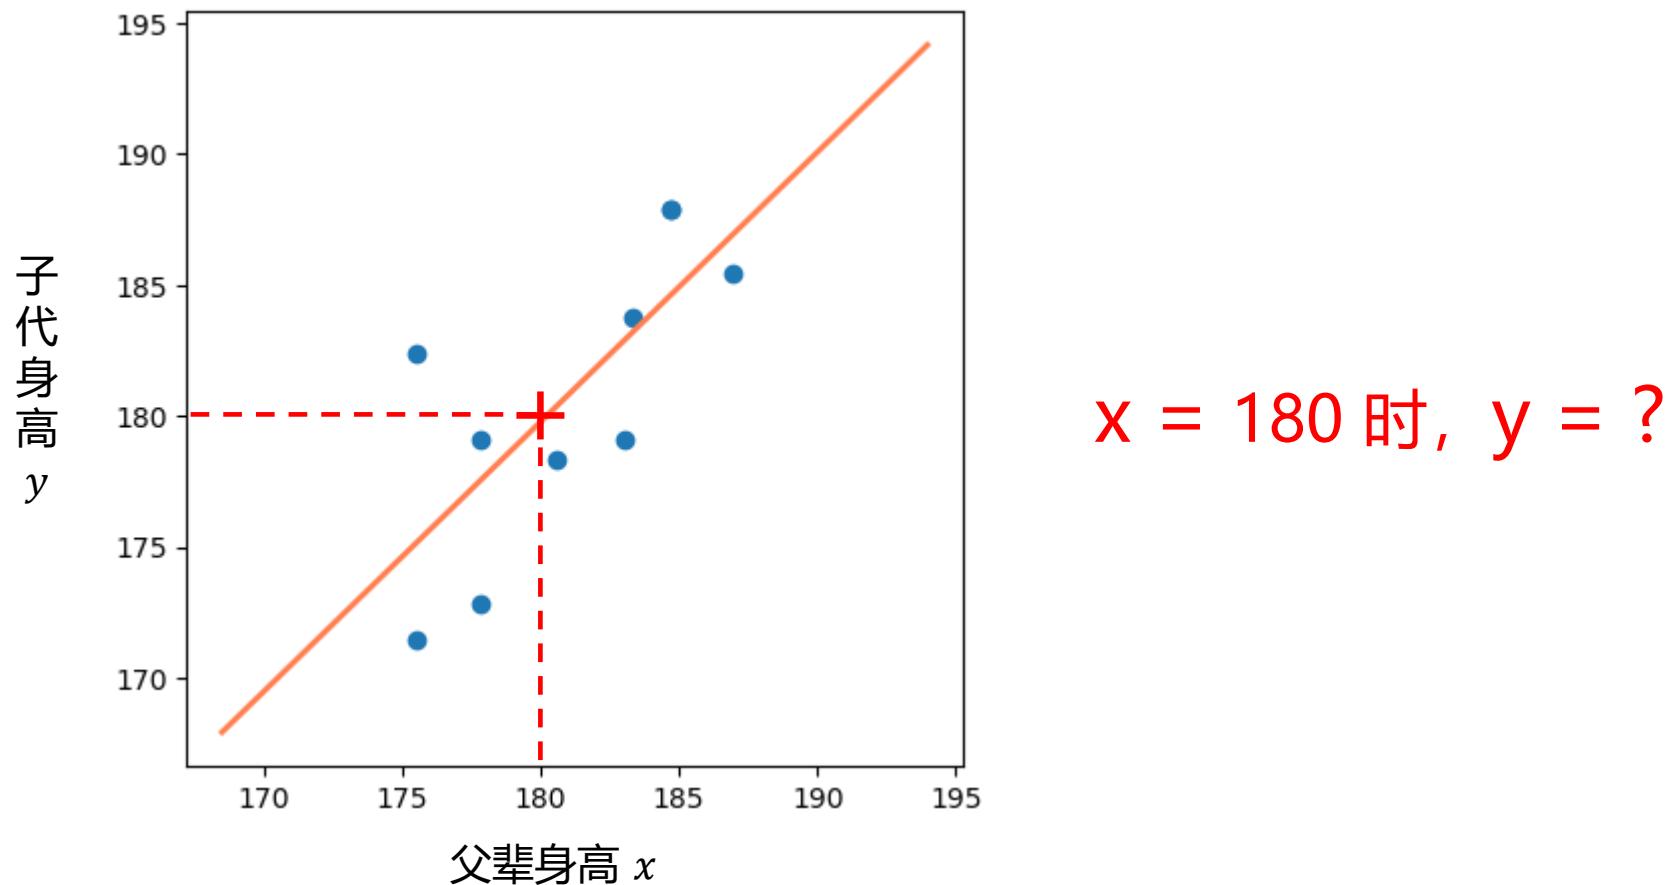
哈尔滨工业大学（深圳）

目录

- 回归预测的基本概念
- 线性回归
- 基于梯度下降法的线性回归
- 基于最小二乘法的线性回归 (optional)

回归预测任务

- 回归 (regression) : 预测给定数据对象的**目标值** (与分类的类别**对应**)



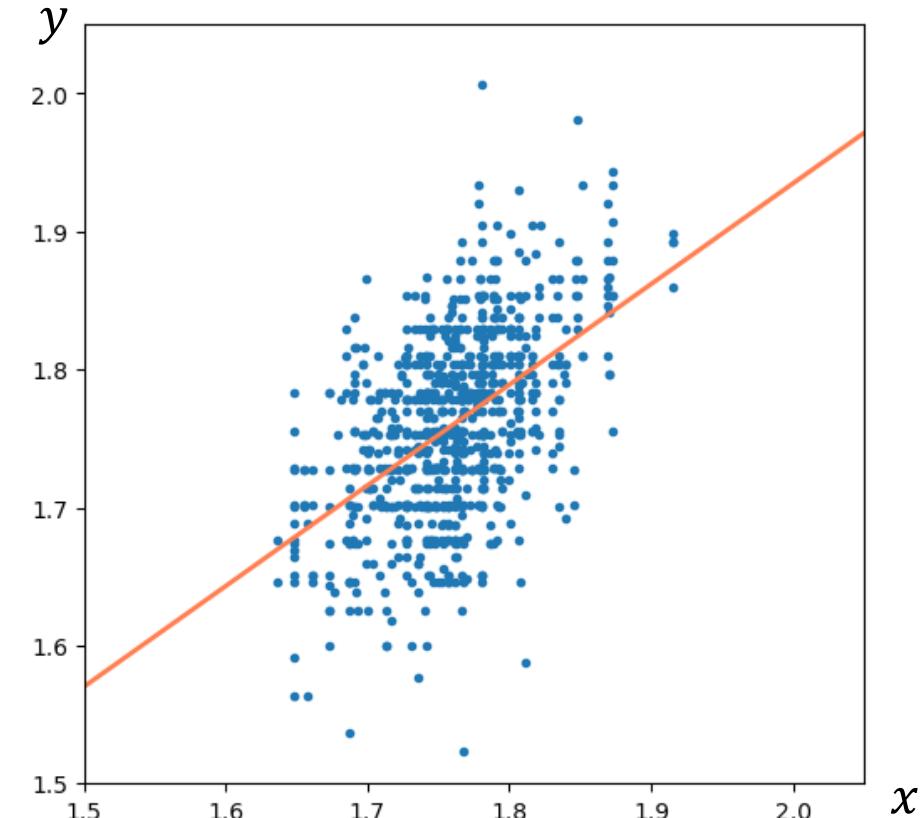
回归预测举例

- 根据父母平均身高，预测子女成年身高。 (Francis Galton , 1886)

- 观察了205对父母及每对父母的后代
- 总的的趋势：父辈的身材偏高（矮）时，
子代的身材也偏高（矮）
- 子代的身高 y 与父母平均身高 x 大致满足：

$$y = 0.477 + 0.729x \text{ (米)}$$

- 回归 (regression)：
子代身高的分布不会向高矮两个极端发展，
而是趋于“回归”到父辈身高的平均值



回归任务的定义

- 回归任务可以用一个形式化函数表示：

$$y = f(\textcolor{red}{x}),$$

其中 $\textcolor{red}{x} \in \mathbb{D}, y \in \mathbb{R}$

- 回归函数 $f(\textcolor{red}{x})$ 经过运算可以输出一个连续的实数值 y ，即“回归模型”

如何构造回归函数 $f(\textcolor{red}{x})$ 呢？

回归预测的应用领域

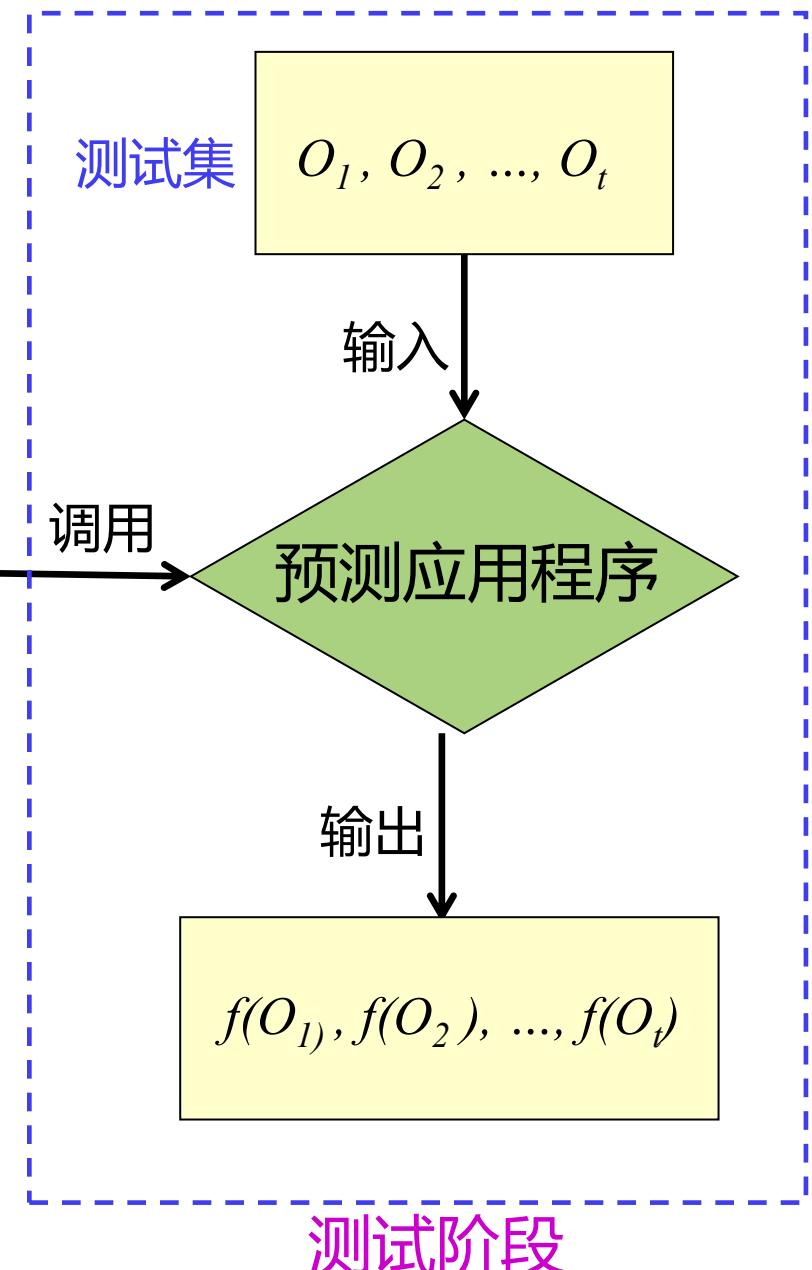
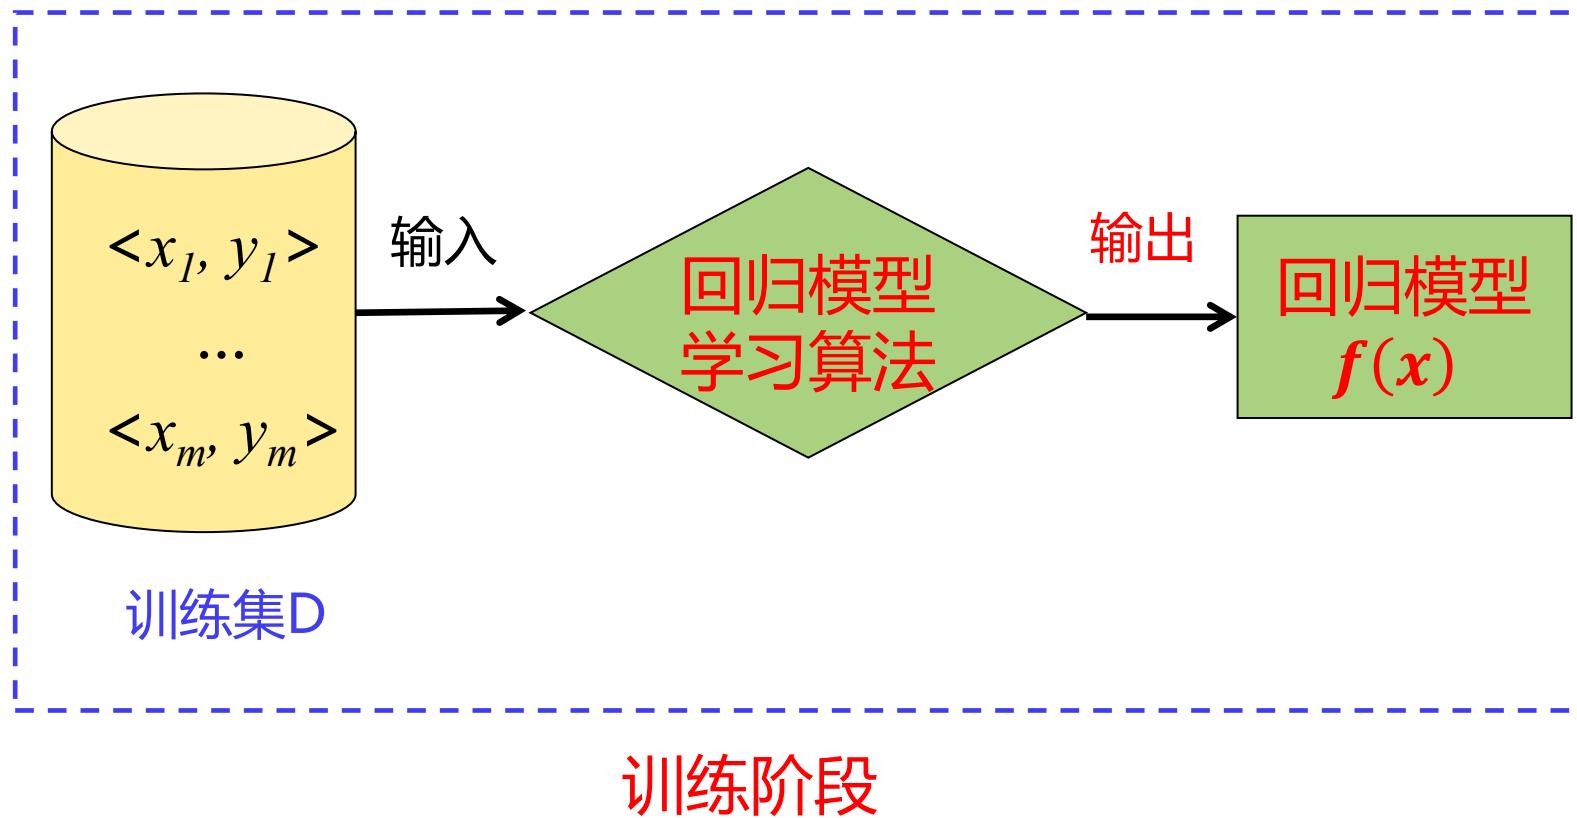
- 几乎每个人工智能应用领域都涉及到预测问题

- 股票预测
- 贷款额度估计
- 视频预测
- 销售业绩预测
- 医学诊断
- 欺诈检测
-

完成回归任务的“两阶段”流程

- 回归模型构建（训练阶段）：即学习阶段
 - 从目标值（target value）已知的训练数据集中学习，生成回归模型 $f(\textcolor{red}{x})$
 - 回归模型可表示成线性函数、超平面、回归树等形式
- 回归模型应用（测试阶段）：
 - 用回归模型 $f(\textcolor{red}{x})$ 来预测新的数据对象的目标值

回归模型的训练与应用



常用的回归方法

- 线性回归

- 套索回归 (Lasso Regression)
- 岭回归 (Ridge Regression)
- 弹性网络回归 (ElasticNet Regression)

- 非线性回归

- KNN回归 (K Neighbors Regression)
- 决策树回归 (Decision Tree Regression)
- 支持向量回归 (Support Vector Regression, SVR)
- 集成学习回归：随机森林、AdaBoost、XGBoost、LightGBM
- 神经网络与深度学习



线性回归

应用案例

- 预测下一天的日均气温 $y = f(x)$, 其中 $x \in \mathbb{D}, y \in \mathbb{R}$
 - Kaggle数据集 (daily climate time series data)

日期	日均气温 (mean temp)	相对湿度 (humidity)	风速 (wind speed)	气压 (pressure)
...
2017-01-02	7.40	92.00	2.980	1017.80
2017-01-03	7.17	87.00	4.63	1018.67

y

f

x

<https://www.kaggle.com/sumanthvrao/daily-climate-time-series-data>

线性回归模型

- 给定数据集 $\mathbb{X} = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_n, y_n)\}$, 其中, 每个样本 \mathbf{x}_i 有 d 个特征:

$$\mathbf{x}_i = (x_{i,1}; x_{i,2}; \dots; x_{i,d})^T, \quad y_i \in \mathbb{R}.$$

- 线性模型的目的是学习一个关于 \mathbf{x} 的线性函数 $f(\mathbf{x})$, 来尽可能准确地预测 y

$$f(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + b, \quad \mathbf{w} = \begin{pmatrix} w_1 \\ w_2 \\ \dots \\ w_d \end{pmatrix}$$
$$y \approx f(\mathbf{x})$$

- 即: $f(\mathbf{x})$ 与 y 之间的误差越小越好.
- 其中 \mathbf{w} 与 b 是需要学习的参数项.

在前面的案例中,

日均气温 (mean temp)	相对湿度 (humidity)	风速 (wind speed)	气压 (pressure)
7.40	92.00	2.980	1017.80

$$\mathbf{x}_i = (x_{i,t}, x_{i,h}, x_{i,w}, x_{i,p})^T$$

线性回归模型的优劣评价方法

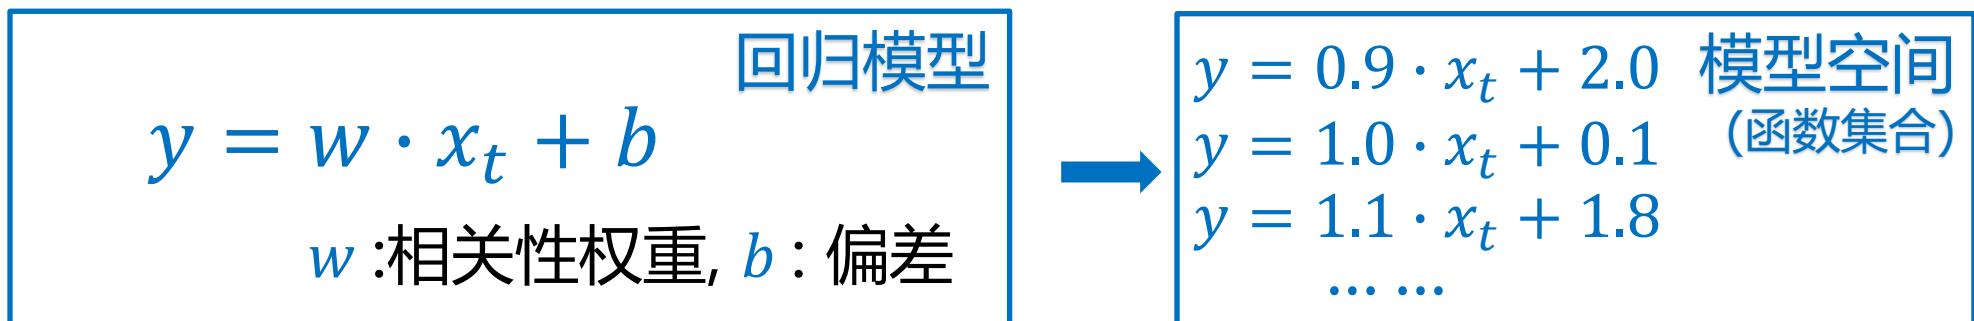
- 在求解 w 和 b 之前，需要给出衡量 $f(x)$ 与 y 之间误差的损失函数
- 在回归方法中，均方误差是比较常用的损失函数，其损失函数定义如下：

$$L(w, b) = \frac{1}{2n} \sum_{i=1}^n (f(\mathbf{x}_i) - y_i)^2 \quad (\mathbf{x}_i, y_i)$$
$$f(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + b$$

单变量线性回归

- 第一步：确定模型空间

- 直观想法：下一天的日均气温很可能与前一天的日均气温相关



线性回归模型: $f(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + b$

数据: (\mathbf{x}_i, y_i)

日均气温 (mean temp)	相对湿度 (humidity)	风速 (wind speed)	气压 (pressure)
7.40	92.00	2.980	1017.80

$\mathbf{x}_i = (x_{i,t}, x_{i,h}, x_{i,w}, x_{i,p})^T$

损失函数

- 第二步：模型优劣的评价标准

$$L(w, b) = \sum_{i=1}^n [y_i - (w \cdot x_{i,t} + b)]^2$$

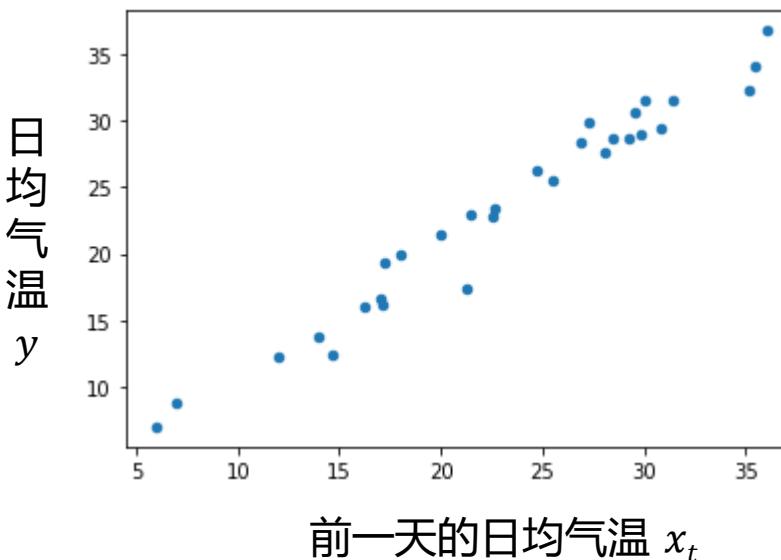
预测误差
预测值

$y = 0.9 \cdot x_t + 2.0$ 模型空间
 $y = 1.0 \cdot x_t + 0.1$ (函数集合)
 $y = 1.1 \cdot x_t - 1.8$
....

- 为了便于计算，随机选取了三十天的数据作为训练集(单位， $^{\circ}\text{C}$)

$(x_{1,t}, y_1)$
 $(x_{2,t}, y_2)$
⋮
 $(x_{30,t}, y_{30})$

散点图

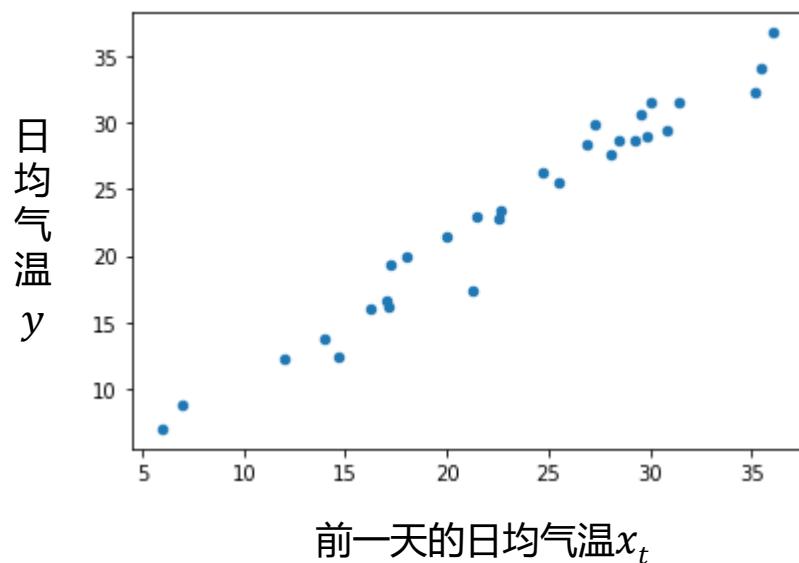


损失函数

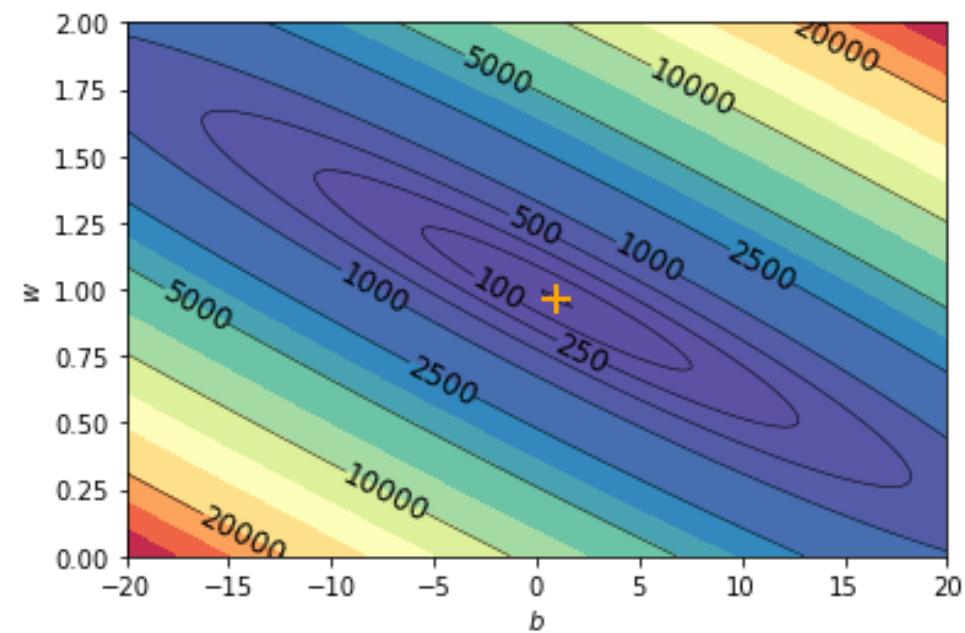
- 损失函数等值线图

$$L(w, b) = \sum_{i=1}^n (y_i - w \cdot x_{i,t} - b)^2$$

如何寻找最小值点?



模型空间



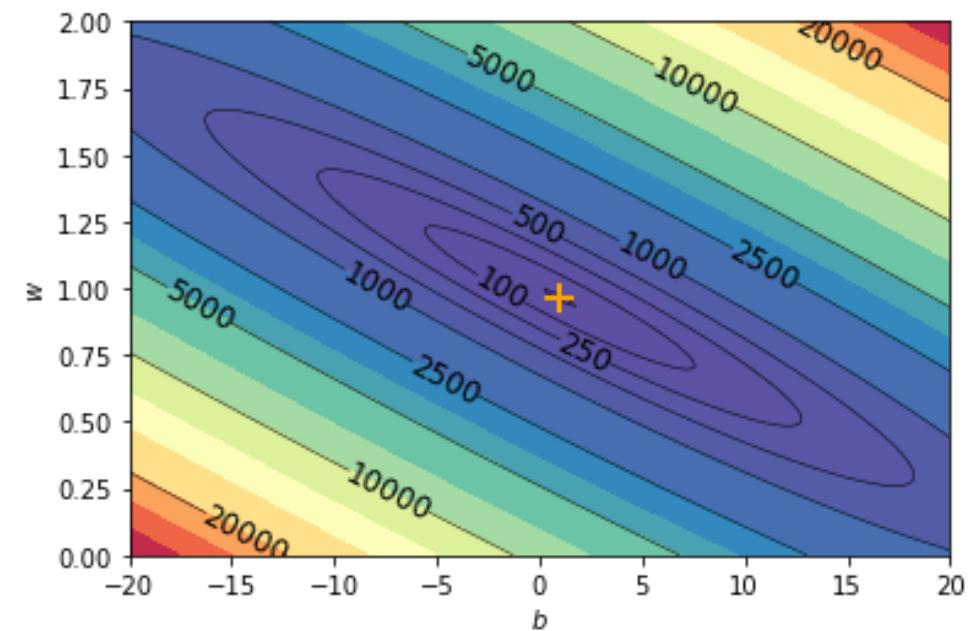
最优化算法

- 第三步：找到“最优”模型
- 寻找一组最优的参数 (w^*, b^*) ，能够最小化损失函数，即

$$w^*, b^* = \arg \min_{b, w} L(w, b)$$

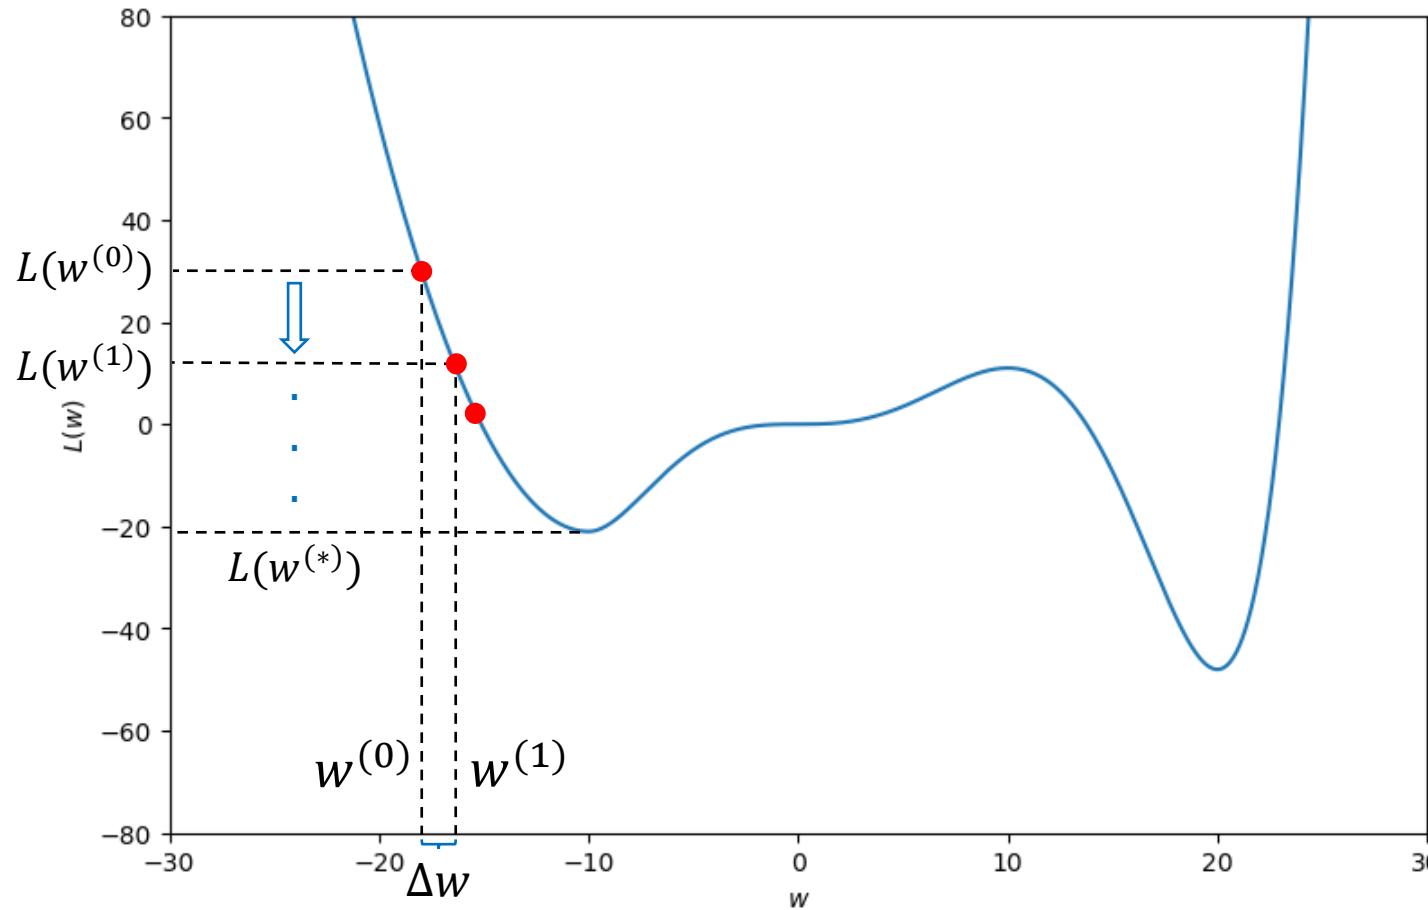
$$= \arg \min_{b, w} \sum_{i=1}^n [y_i - (w \cdot x_{i,t} + b)]^2$$

- 常用算法：
 - 梯度下降法
 - 最小二乘法（小规模数据）



基于梯度下降法的线性回归模型

梯度下降法的基本思想



梯度下降法的数学原理(一元函数)

- 一元函数泰勒公式

- 如果一元函数 $L(w)$ 在点 $w^{(0)}$ 的某一邻域内可导, 则有

$$L(w) = L(w^{(0)}) + L'(w^{(0)})(w - w^{(0)}) + o(w - w^{(0)})$$

- 如果变化量 $\Delta w = w - w^{(0)} = -\eta L'(w^{(0)})$, 学习率 η 为一个较小的正数, 则

“负梯度方向”

$$L(w) \approx L(w^{(0)}) - L'(w^{(0)}) \cdot \eta L'(w^{(0)})$$

$$= L(w^{(0)}) - \eta \left(L'(w^{(0)}) \right)^2$$

$$< L(w^{(0)})$$

附注: $L'(w^{(0)}) = \frac{dL}{dw} |_{w=w^{(0)}}$

梯度下降法的数学原理(多元函数)

- 对于线性回归模型 $f(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + b$, $\mathbf{w} = \begin{pmatrix} w_1 \\ w_2 \\ \dots \\ w_d \end{pmatrix}$, 损失函数 $L(\mathbf{w}, b)$ 为多元函数
- 为了简洁起见, 将待求解参数 \mathbf{w} 和 b 表示为 \mathbf{W} , $\mathbf{W} = \begin{pmatrix} b \\ \mathbf{w} \end{pmatrix}$
- 将一元函数泰勒公式 $L(w) = L(w^{(0)}) + L'(w^{(0)})(w - w^{(0)}) + o(w - w^{(0)})$ 推广, 可以得到多元函数泰勒公式 :
 - 如果多元函数 $L(\mathbf{W})$ 在点 $\mathbf{W}^{(0)}$ 的某一邻域内有一阶连续偏导数, 则有

$$L(\mathbf{W}) = L(\mathbf{W}^{(0)}) + \nabla L(\mathbf{W}^{(0)})^T (\mathbf{W} - \mathbf{W}^{(0)}) + o(\mathbf{W} - \mathbf{W}^{(0)}),$$

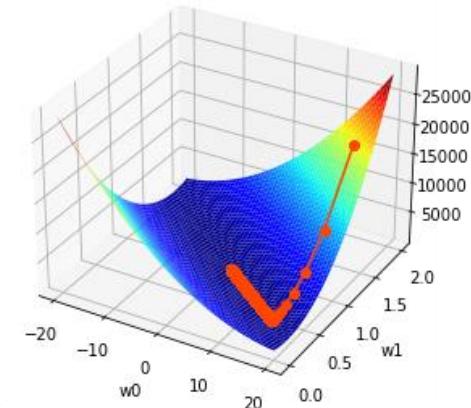
其中 ∇ 为梯度算子 (nabla operator)

附注: $\nabla L(\mathbf{W}^{(0)}) = \left(\frac{\partial L}{\partial b} \Big|_{\mathbf{W}=\mathbf{W}^{(0)}}, \frac{\partial L}{\partial w_1} \Big|_{\mathbf{W}=\mathbf{W}^{(0)}}, \frac{\partial L}{\partial w_2} \Big|_{\mathbf{W}=\mathbf{W}^{(0)}}, \dots, \frac{\partial L}{\partial w_d} \Big|_{\mathbf{W}=\mathbf{W}^{(0)}} \right)^T$

梯度下降法的数学原理(多元函数)

- 多元函数 $L(\mathbf{W})$ 在点 $\mathbf{W}^{(0)}$ 处的梯度 $\nabla L(\mathbf{W}^{(0)})$ 为一个向量：

- 梯度的方向与取得最大方向导数的方向一致，
- 梯度的模为方向导数的最大值。



- 根据公式 $L(\mathbf{W}) = L(\mathbf{W}^{(0)}) + \nabla L(\mathbf{W}^{(0)})^T (\mathbf{W} - \mathbf{W}^{(0)}) + o(\mathbf{W} - \mathbf{W}^{(0)})$,

如果变化量 $\Delta\mathbf{W} = \mathbf{W} - \mathbf{W}^{(0)} = -\eta \nabla L(\mathbf{W}^{(0)})$, 学习率 η 为一个较小的正数, 则

“负梯度方向”

$$L(\mathbf{W}) \approx L(\mathbf{W}^{(0)}) - \eta \nabla L(\mathbf{W}^{(0)})^T \nabla L(\mathbf{W}^{(0)})$$



函数值下降

$$\begin{aligned} &= L(\mathbf{W}^{(0)}) - \eta \|\nabla L(\mathbf{W}^{(0)})\|^2 \\ &< L(\mathbf{W}^{(0)}) \end{aligned}$$

梯度下降法的算法流程（单个参数）

- 以一个仅有单个参数 w 的光滑的损失函数 $L(w)$ 为例，梯度下降法：
随机选取初始值 $w^{(0)}$

$$w^{(1)} \leftarrow w^{(0)} - \eta \frac{dL}{dw} \Big|_{w=w^{(0)}}$$

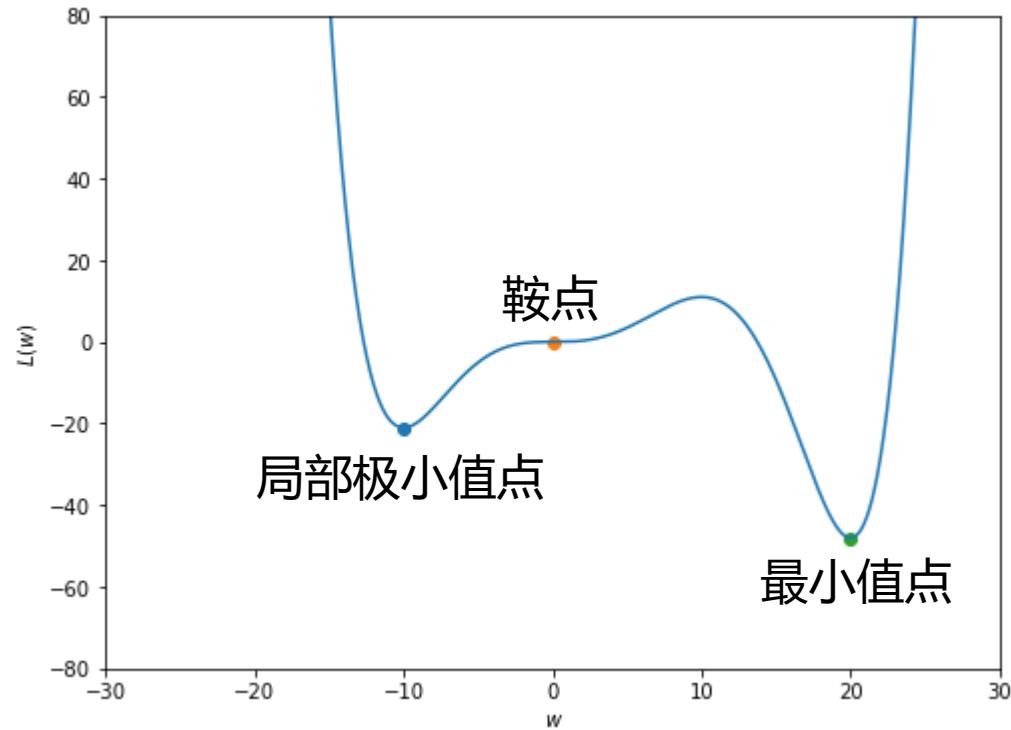
$$w^{(2)} \leftarrow w^{(1)} - \eta \frac{dL}{dw} \Big|_{w=w^{(1)}}$$

... ...

$$w^{(j+1)} \leftarrow w^{(j)} - \eta \frac{dL}{dw} \Big|_{w=w^{(j)}}$$

... ...

直到 $|w^{(n+1)} - w^{(n)}| < \varepsilon$, ε 为终止条件



梯度下降法的算法流程（两个参数）

- 案例的损失函数 $L(w, b)$ 含有两个参数

$$L(w, b) = \sum_{i=1}^N (y_i - \textcolor{blue}{w} \cdot x_{i,t} - \textcolor{blue}{b})^2$$

➤ (随机) 选取两个初始值 $b^{(0)}, w^{(0)}$

➤ 计算 $\frac{\partial L}{\partial w}|_{w=w^{(0)}, b=b^{(0)}}, \frac{\partial L}{\partial b}|_{w=w^{(0)}, b=b^{(0)}},$ 更新 b, w

$$\nabla L(b, w) = \begin{pmatrix} \frac{\partial L}{\partial b} \\ \frac{\partial L}{\partial w} \end{pmatrix}$$

$$w^{(1)} \leftarrow w^{(0)} - \eta \frac{\partial L}{\partial w}|_{w=w^{(0)}, b=b^{(0)}}, \quad b^{(1)} \leftarrow b^{(0)} - \eta \frac{\partial L}{\partial b}|_{w=w^{(0)}, b=b^{(0)}}$$

➤ 计算 $\frac{\partial L}{\partial w}|_{w=w^{(1)}, b=b^{(1)}}, \frac{\partial L}{\partial b}|_{w=w^{(1)}, b=b^{(1)}},$ 更新 b, w

$$w^{(2)} \leftarrow w^{(1)} - \eta \frac{\partial L}{\partial w}|_{w=w^{(1)}, b=b^{(1)}}, \quad b^{(2)} \leftarrow b^{(1)} - \eta \frac{\partial L}{\partial b}|_{w=w^{(1)}, b=b^{(1)}}$$

... ...

梯度下降法的应用示例

- 计算梯度

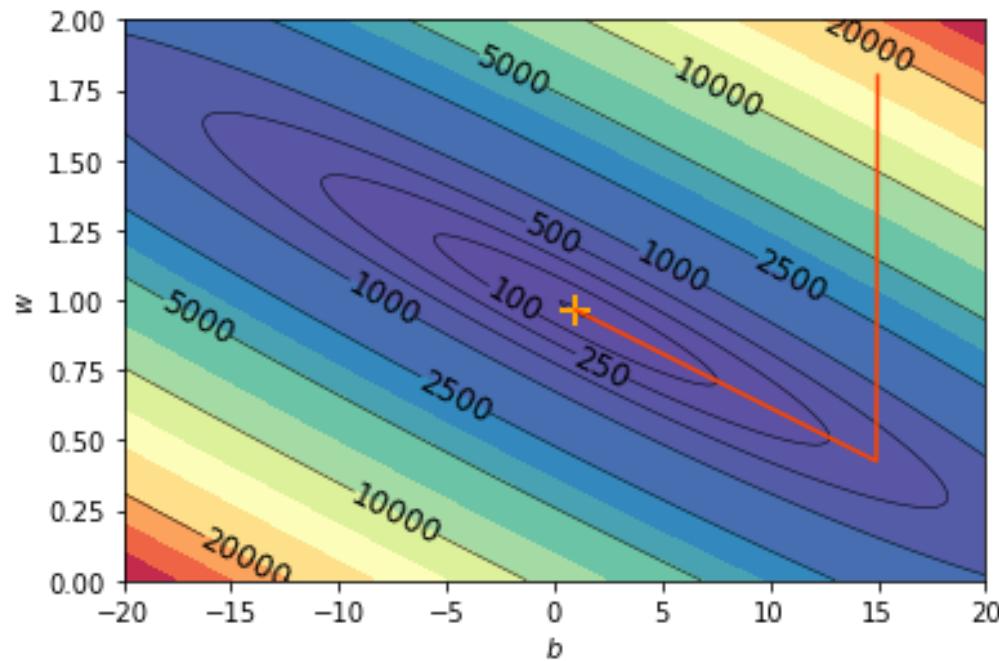
$$L(w, b) = \sum_{i=1}^n (y_i - w \cdot x_{i,t} - b)^2$$

$$\frac{\partial L}{\partial w} = \sum_{i=1}^n 2(y_i - w \cdot x_{i,t} - b)(-x_{i,t})$$

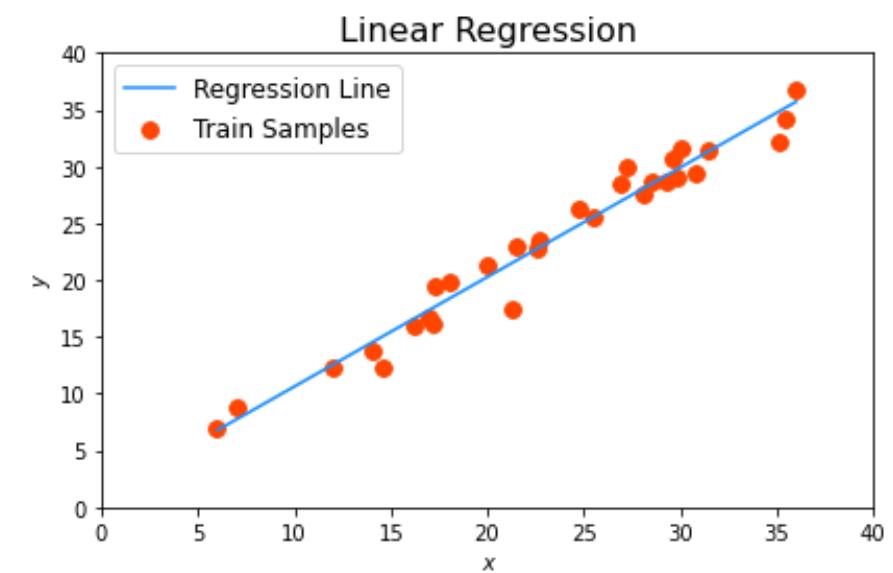
$$\frac{\partial L}{\partial b} = \sum_{i=1}^n 2(y_i - w \cdot x_{i,t} - b)(-1)$$

梯度下降法示例

- 沿梯度下降的方向寻找极小值



$$w^* = 0.965, b^* = 0.980$$



$$y = 0.965x_t + 0.980$$

测试模型效果 (单变量线性回归)

- 训练集均方误差

$$\frac{1}{30} \sum_{i=1}^{30} (y_i - \mathbf{w}^* \cdot \mathbf{x}_{i,t} - b^*)^2 = 2.134$$

- 在测试数据中随机选取十天的数据

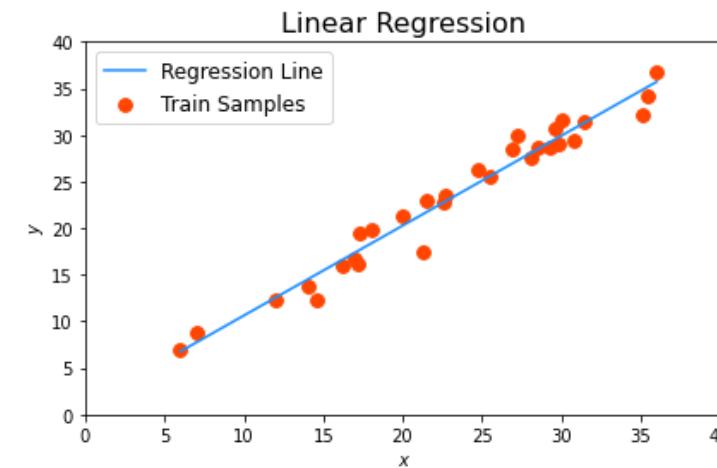
作为测试集，测试模型的泛化性能

- 测试集均方误差

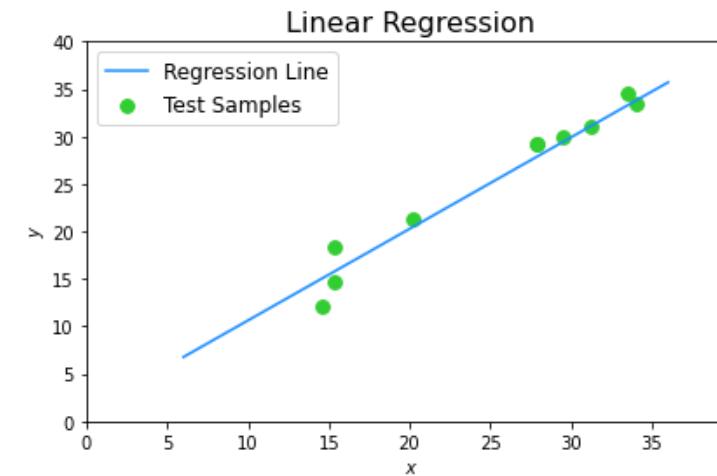
$$\frac{1}{10} \sum_{i=1}^{10} (y_i - \mathbf{w}^* \cdot \mathbf{x}_{i,t} - b^*)^2 = 2.294$$

- 测试集平均误差

$$\frac{1}{10} \sum_{i=1}^{10} |y_i - \mathbf{w}^* \cdot \mathbf{x}_{i,t} - b^*| = 1.229$$



$$w^* = 0.965, b^* = 0.980$$



改进模型：增加二次项特征

- 回归模型：

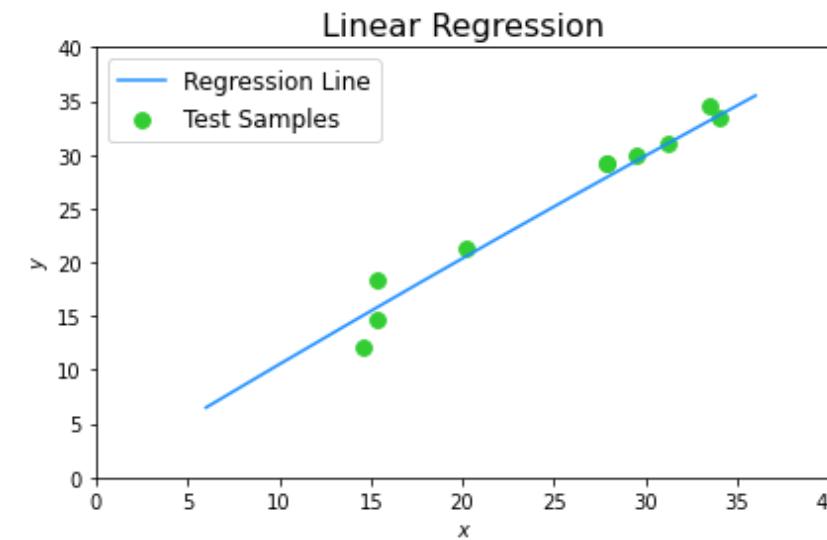
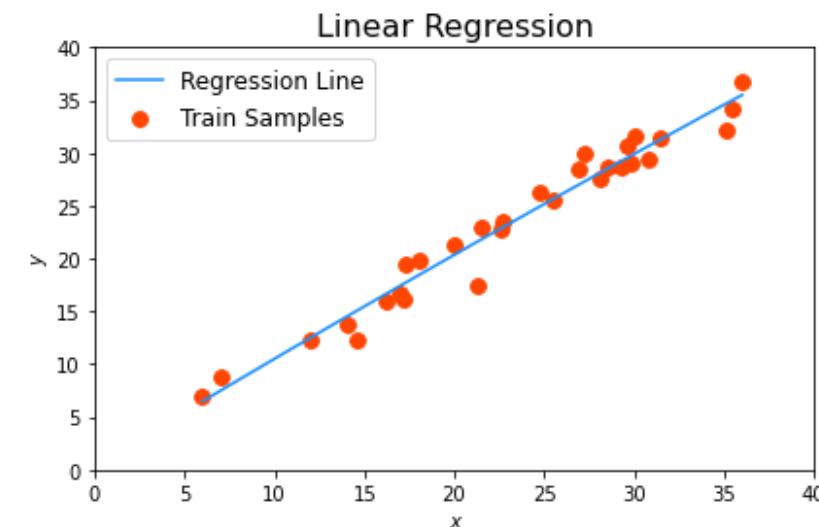
$$y = w_2 \cdot x_t^2 + w_1 \cdot x_t + b$$

- 计算模型参数，可得

$$w_2^* = -1.50 \times 10^{-3}, w_1^* = 1.030, b^* = 0.361$$

- 模型误差：

- 训练集均方误差： $2.123 < 2.134$
- 测试集均方误差： $2.278 < 2.294$



改进模型：增加三次项特征

- 回归模型：

$$y = w_3 \cdot x_t^3 + w_2 \cdot x_t^2 + w_1 \cdot x_t + b$$

- 计算模型参数，可得

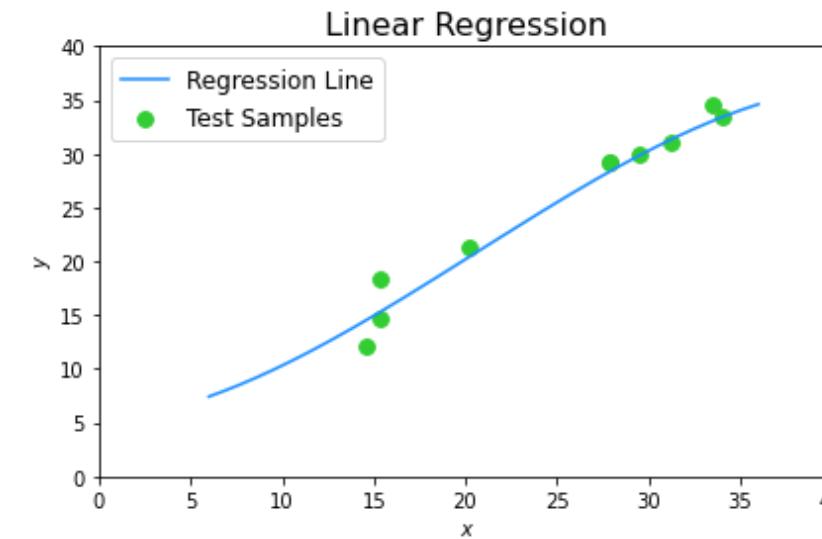
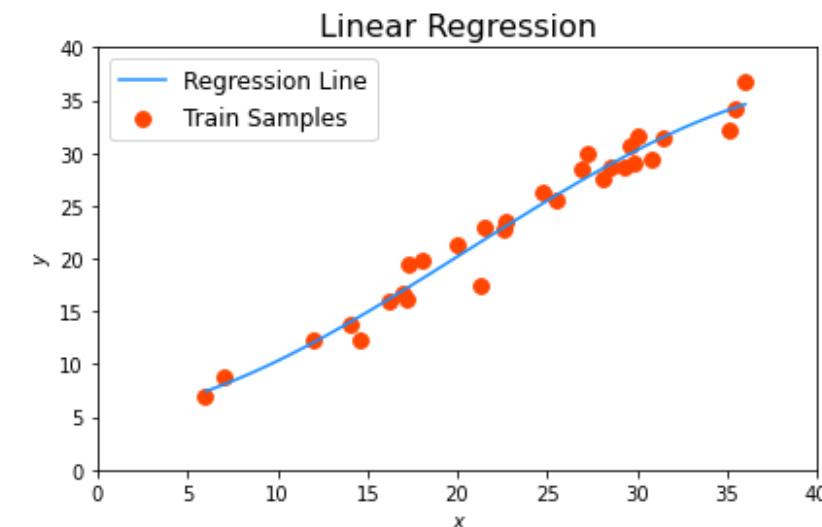
$$w_3^* = -7.43 \times 10^{-4}, w_2^* = 0.046,$$

$$w_1^* = 0.136, b^* = 5.123$$

- 模型误差：

➤ 训练集均方误差： $1.913 < 2.123$

➤ 测试集均方误差： $2.042 < 2.278$



改进模型：增加四次项特征

- 回归模型：

$$y = w_4 \cdot x_t^4 + w_3 \cdot x_t^3 + w_2 \cdot x_t^2 + w_1 \cdot x_t + b$$

- 计算模型参数，可得

$$w_4^* = 4.75 \times 10^{-5}, w_3^* = -4.83 \times 10^{-3},$$

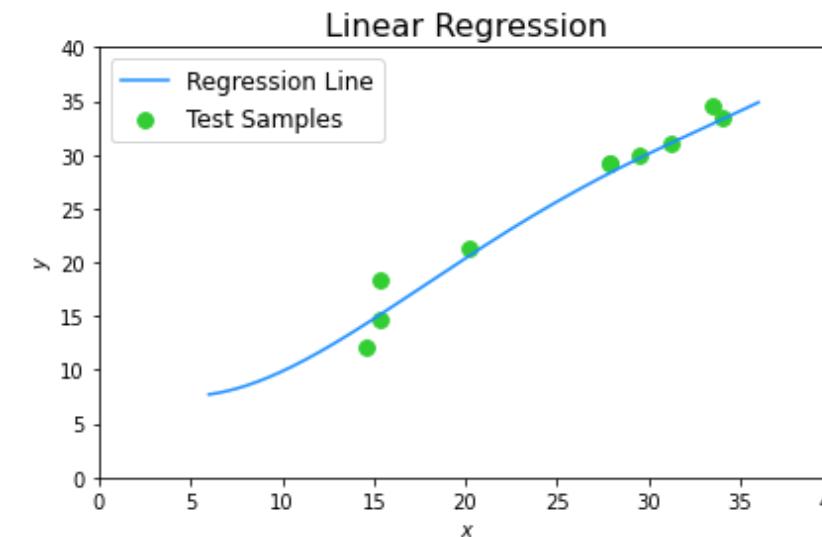
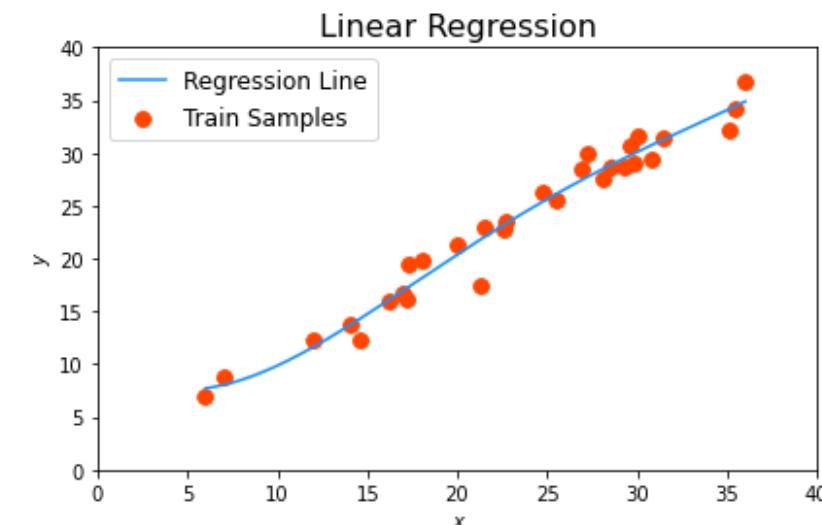
$$w_2^* = 0.167, w_1^* = -1.290, b^* = 10.43$$

- 模型误差：

➤ 训练集均方误差： $1.878 < 1.913$

➤ 测试集均方误差： $2.053 > 2.042$

过拟合



改进模型：增加五次项特征

- 回归模型：

$$y = w_5 \cdot x_t^5 + w_4 \cdot x_t^4 + w_3 \cdot x_t^3 + w_2 \cdot x_t^2 + w_1 \cdot x_t + b$$

- 计算模型参数，可得

$$w_5^* = 1.184 \times 10^{-5}, w_4^* = -1.22 \times 10^{-3}, w_3^* = 4.64 \times 10^{-2},$$

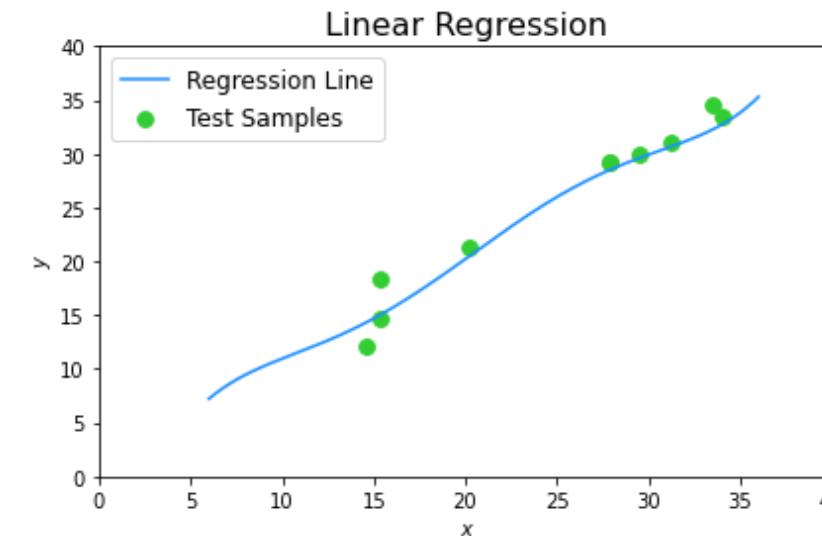
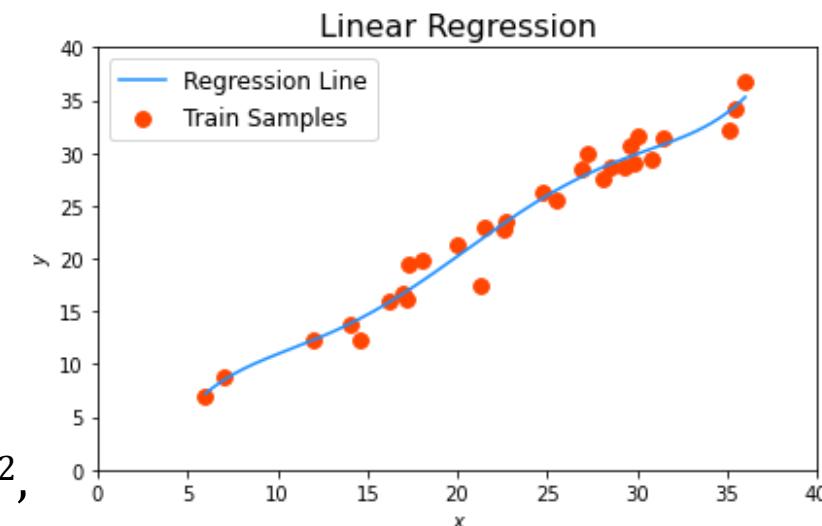
$$w_2^* = -0.080, w_1^* = 6.948, b^* = -14.37$$

- 模型误差：

➤ 训练集均方误差： $1.797 < 1.878$

➤ 测试集均方误差： $2.396 > 2.053$

过拟合



过拟合

- 复杂的模型可以更好地拟合训练数据
- 但未必会在测试数据上获得更好的效果

$$y = w \cdot x_t + b$$

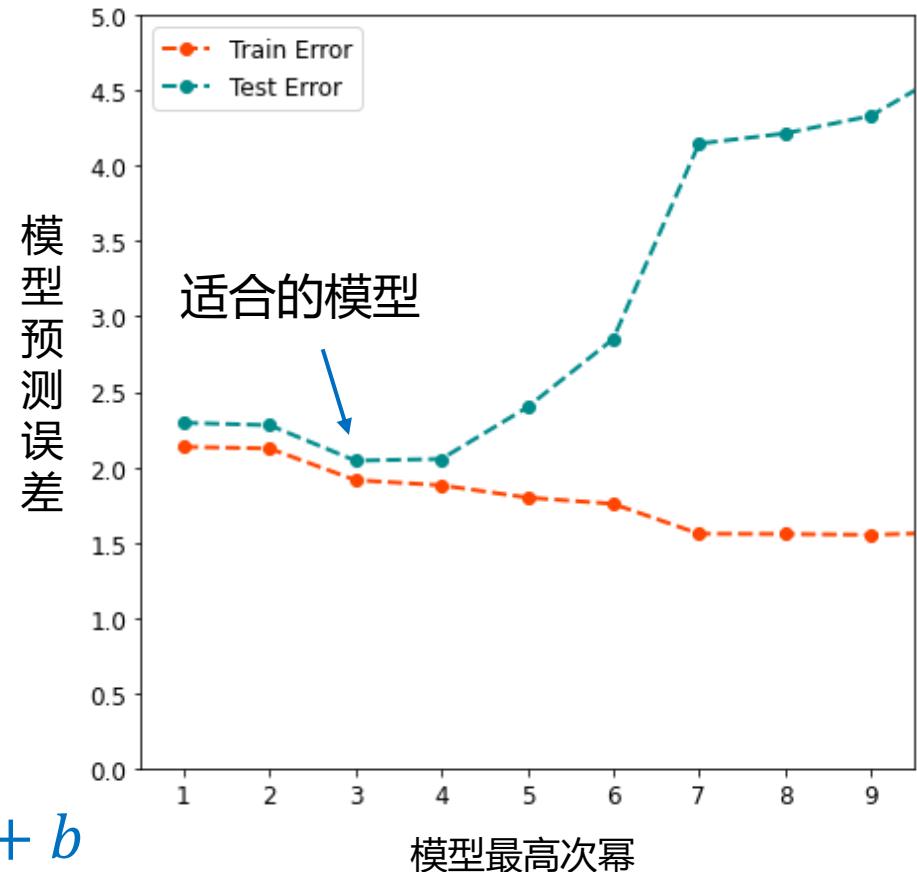
$$y = w_2 \cdot x_t^2 + w_1 \cdot x_t + b$$

$$y = w_3 \cdot x_t^3 + w_2 \cdot x_t^2 + w_1 \cdot x_t + b$$

$$y = w_4 \cdot x_t^4 + w_3 \cdot x_t^3 + w_2 \cdot x_t^2 + w_1 \cdot x_t + b$$

$$y = w_5 \cdot x_t^5 + w_4 \cdot x_t^4 + w_3 \cdot x_t^3 + w_2 \cdot x_t^2 + w_1 \cdot x_t + b$$

....



多变量线性回归

- 回到第一步：确定模型空间

- 除前一天的日均气温外，考虑与前一天的相对湿度、风速、气压是否相关

$$y = w_1 \cdot x_t + w_2 \cdot x_t^2 + w_3 \cdot x_t^3 + w_4 \cdot x_h + w_5 \cdot x_w + w_6 \cdot x_p + b$$

线性回归模型： $f(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + b$

数据： (\mathbf{x}_i, y_i)

	日均气温 (mean temp)	相对湿度 (humidity)	风速 (wind speed)	气压 (pressure)
\mathbf{x}_i	7.40	92.00	2.980	1017.80

$\mathbf{x}_i = (x_{i,t}, x_{i,h}, x_{i,w}, x_{i,p})^T$

增加其他特征变量

- 回归模型：

$$y = w_1 \cdot x_t + w_2 \cdot x_t^2 + w_3 \cdot x_t^3 \\ + w_4 \cdot x_h + w_5 \cdot x_w + w_6 \cdot x_p + b$$

- 计算模型参数，可得

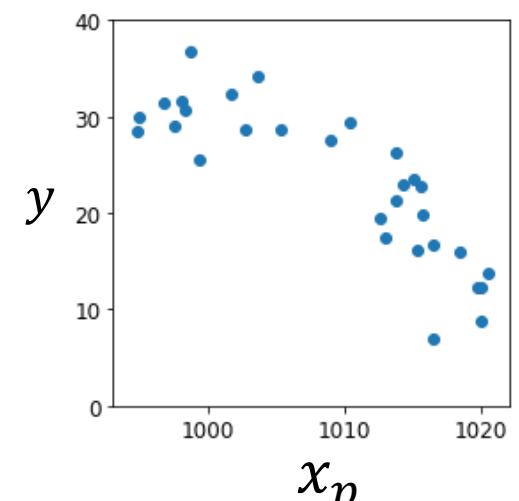
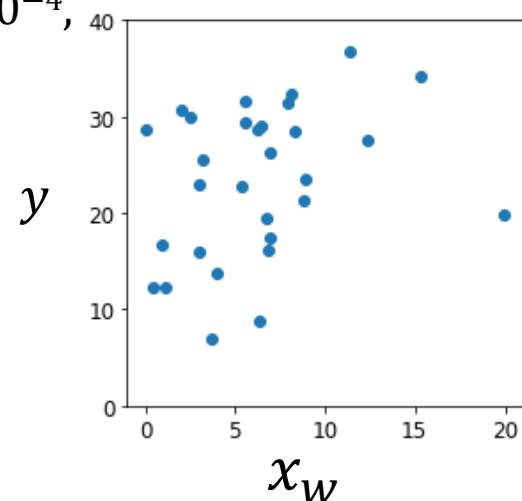
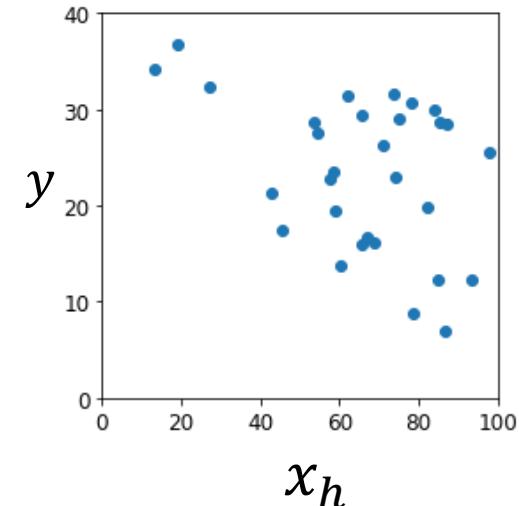
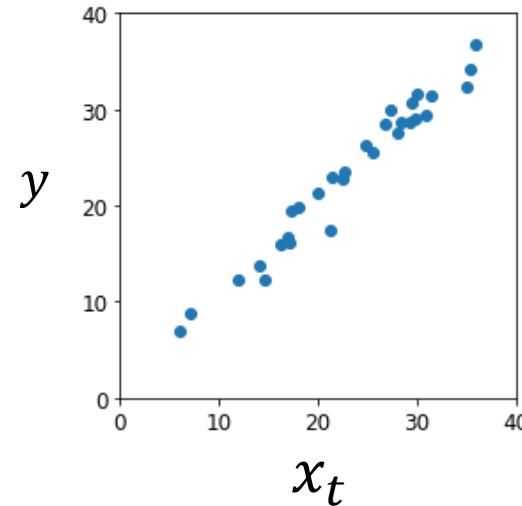
$$w_6^* = -0.011, w_5^* = 0.010, w_4^* = 1.18 \times 10^{-2}, w_3^* = -2.58 \times 10^{-4}, \\ w_2^* = 1.39 \times 10^{-2}, w_1^* = 0.667, b^* = 109.5$$

- 模型误差：

➤ 训练集均方误差： $1.553 < 1.913$

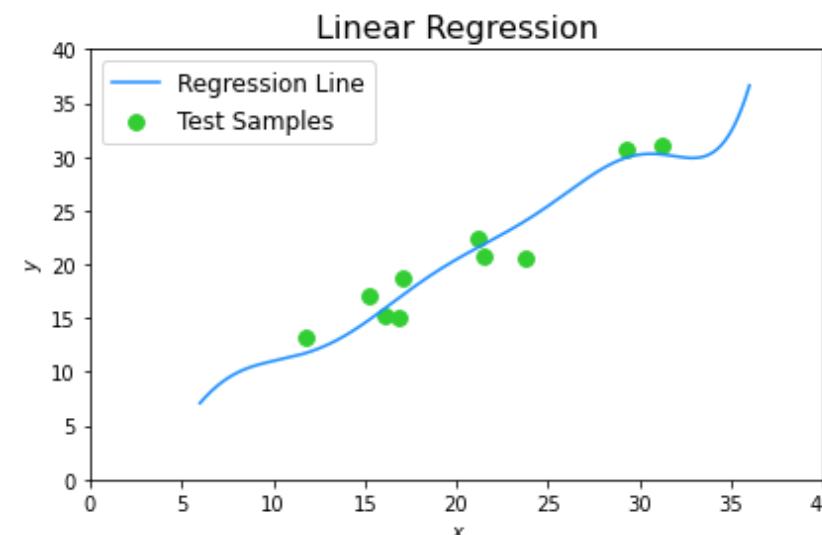
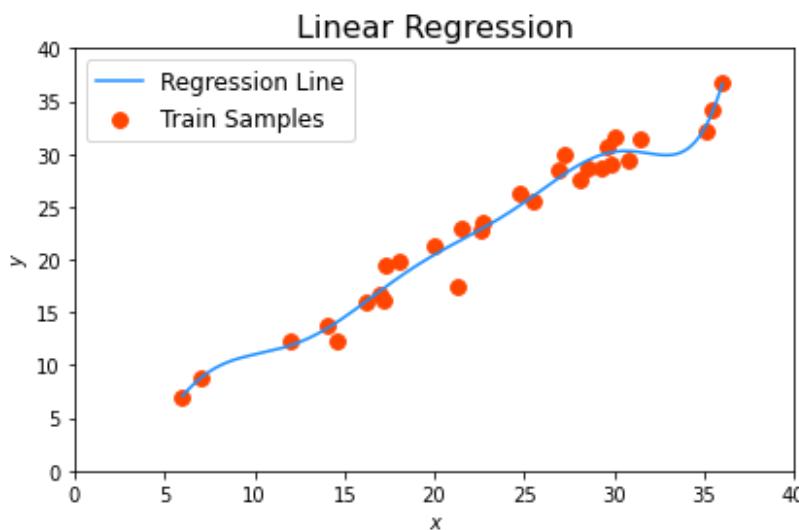
➤ 测试集均方误差： $2.278 > 2.042$

过拟合



正则化的基本思想

- 奥卡姆剃刀(Occam's razor)原理
 - 选择能够很好地解释已知数据但更简单的模型。
- 简单的函数更为平滑，也就不容易发生过拟合的问题。



$$y = w_{10} \cdot x_t^{10} + w_9 \cdot x_t^9 + \cdots + w_2 \cdot x_t^2 + w_1 \cdot x_t + b$$

正则化

- 对于有 d 个特征的线性回归模型

$$y = \sum_{i=1}^d w_j x_j + b$$

- 损失函数为

$$L(w, b) = \sum_{i=1}^n \left(y_i - \sum_{j=1}^d w_j x_{i,j} - b \right)^2$$

- 加入正则化项的损失函数

➤ L1正则化

$$L(w, b) = \sum_{i=1}^n \left(y_i - \sum_{j=1}^d w_j x_{i,j} - b \right)^2 + \lambda \sum_{j=1}^d |w_j|$$

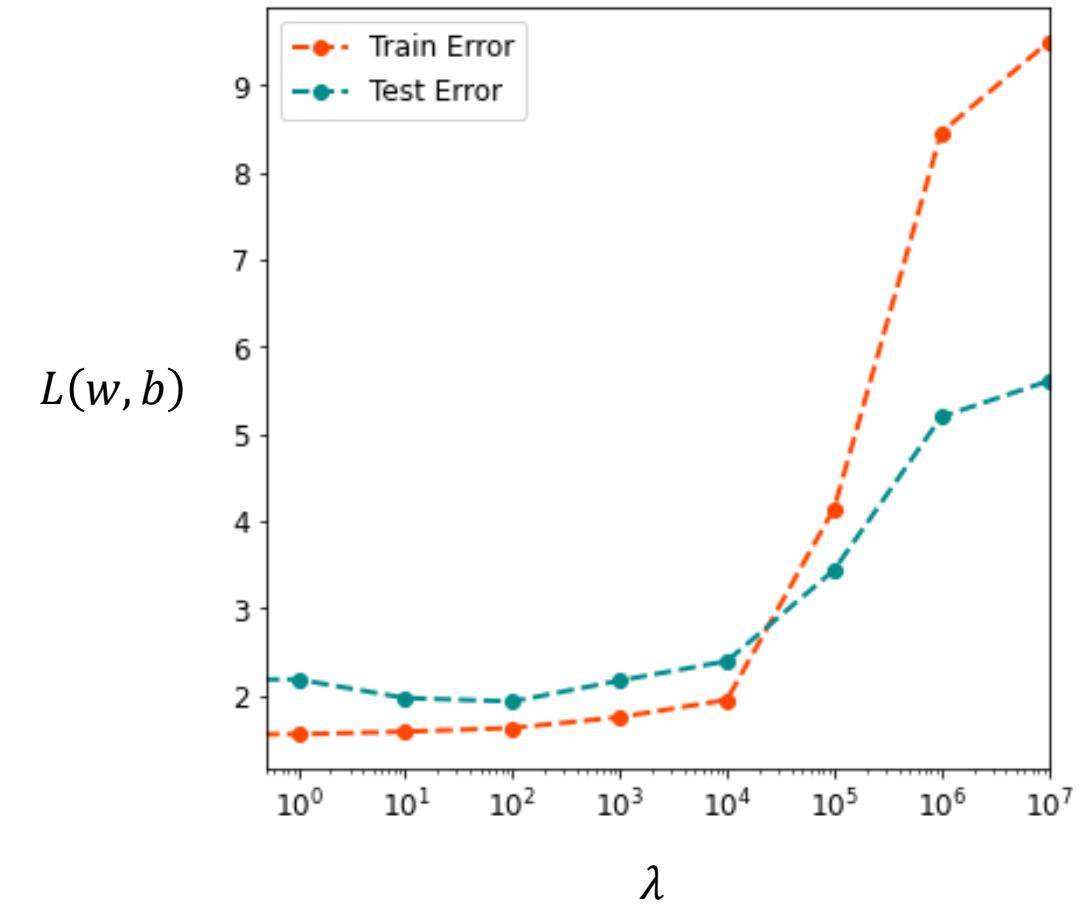
➤ L2正则化

$$L(w, b) = \sum_{i=1}^n \left(y_i - \sum_{j=1}^d w_j x_{i,j} - b \right)^2 + \lambda \sum_{j=1}^d |w_j|^2$$

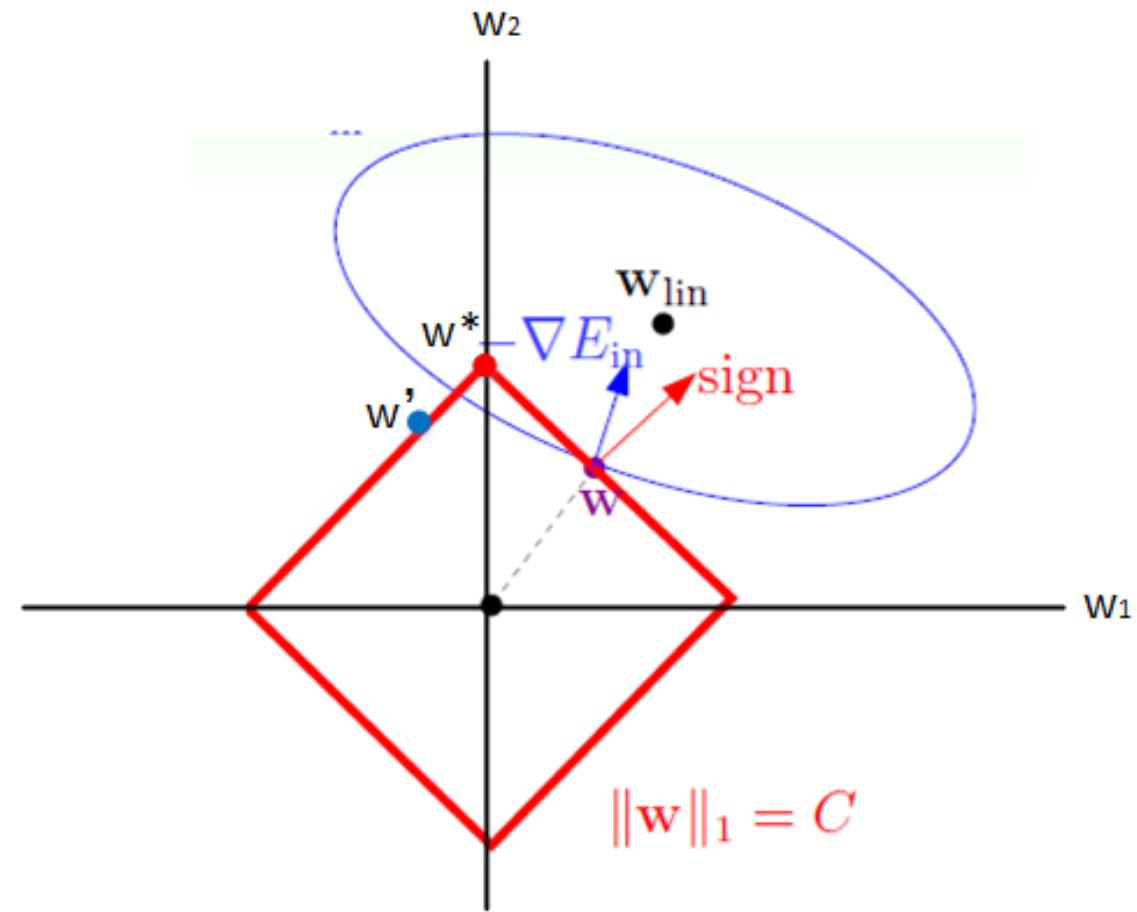
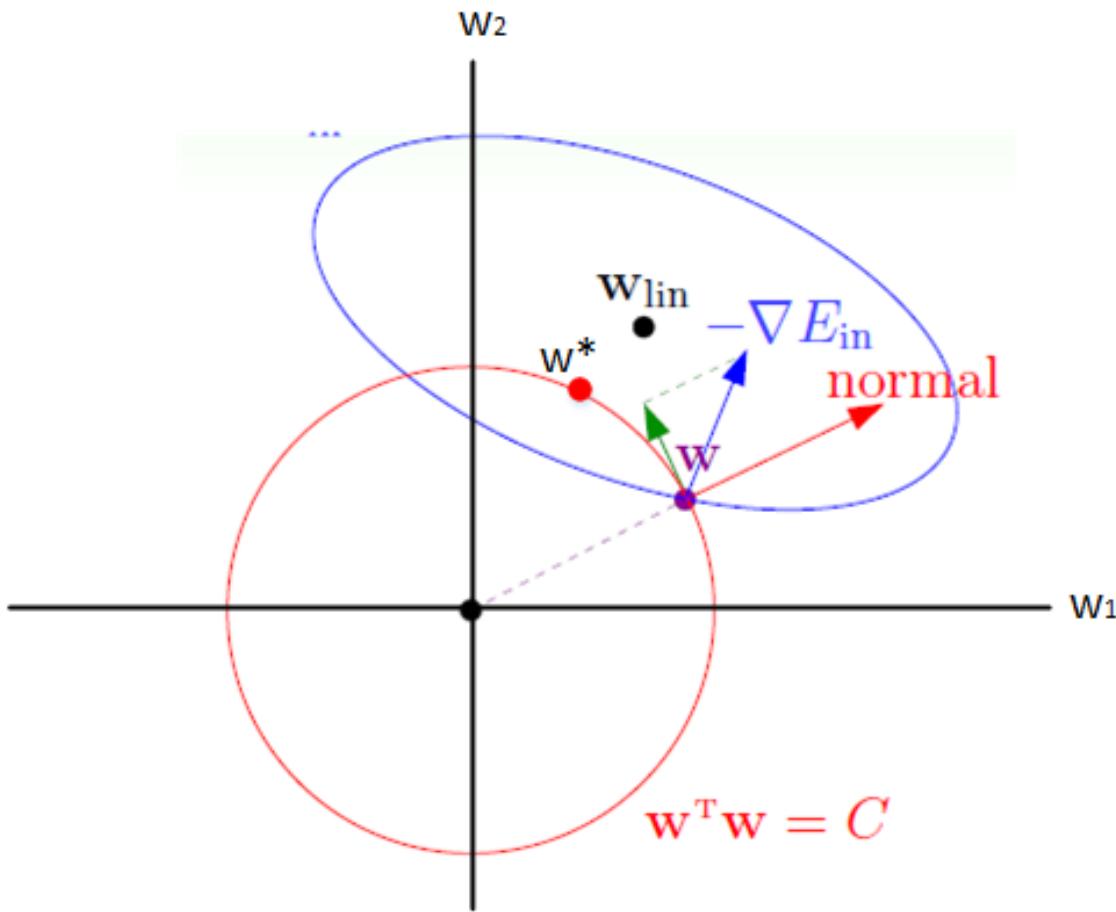
λ 为超参数， λ 值越大，
模型抗扰动能力越强

正则化

- 对于模型: $y = w_1 \cdot x_t + w_2 \cdot x_t^2 + w_3 \cdot x_t^3 + w_4 \cdot x_h + w_5 \cdot x_w + w_6 \cdot x_p + b$
- 损失函数中加入 L2 正则化项
 - $\lambda = 0$ 时:
 - 训练集均方误差: 1.553
 - 测试集均方误差: 2.278
 - $\lambda = 100$ 时:
 - 训练集均方误差: 1.627
 - 测试集均方误差: 1.932



L1、L2正则化方法的特点分析



基于最小二乘法的线性回归模型

基于最小二乘 (Least Square) 法的线性回归模型

- 将数据样本用 $n \times (d + 1)$ 大小的矩阵 \mathbf{X} 表示，每一行是一个样本，每一列是样本的某一个特征，得到

$$\mathbf{x}_i = (x_{i,1}; x_{i,2}; \dots; x_{i,d})$$

$$\mathbf{X} = \begin{pmatrix} 1 & x_{1,1} & \dots & x_{1,d} \\ 1 & x_{2,1} & \dots & x_{2,d} \\ 1 & \dots & \dots & \dots \\ 1 & x_{n,1} & \dots & x_{n,d} \end{pmatrix} \quad f(\mathbf{x}) = \mathbf{w}\mathbf{x} + b$$

- 其中第一列恒置为1，是为了在进行向量乘法与常数项 b 对应

损失函数的向量形式

- 数据集的目标值序列也可写成向量形式 $\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{pmatrix}$ $f(\mathbf{x}) = \mathbf{w}\mathbf{x} + b$
- 为了简洁起见，将待求解参数 \mathbf{w} 和 b 合并为 $\mathbf{W} = \begin{pmatrix} b \\ \mathbf{w} \end{pmatrix}$
- 于是，线性回归的损失函数可重写如下：

$$L(\mathbf{W}) = \frac{1}{2} \sum_{i=1}^n (f(\mathbf{x}_i) - y_i)^2 = \frac{1}{2} (\mathbf{X}\mathbf{W} - \mathbf{y})^T (\mathbf{X}\mathbf{W} - \mathbf{y})$$

最小二乘法的算法流程

- 我们的目标是寻找一组最优的参数 $\mathbf{W}^* = \begin{pmatrix} b^* \\ \mathbf{w}_* \end{pmatrix}$, 能够最小化损失函数:

$$\operatorname{argmin}_{\mathbf{W}} L(\mathbf{W})$$

$$L(\mathbf{W}) = \frac{1}{2} (\mathbf{X}\mathbf{W} - \mathbf{y})^T (\mathbf{X}\mathbf{W} - \mathbf{y})$$

- 当 $\mathbf{X}^T \mathbf{X}$ 可逆时, 对其求导并求驻点可以直接求得 \mathbf{W} 的最优解:

$$\begin{aligned}\frac{\partial L}{\partial \mathbf{W}} &= \frac{1}{2} \frac{\partial}{\partial \mathbf{W}} (\mathbf{W}^T \mathbf{X}^T \mathbf{X} \mathbf{W} - \mathbf{W}^T \mathbf{X}^T \mathbf{y} - \mathbf{y}^T \mathbf{X} \mathbf{W} + \mathbf{y}^T \mathbf{y}) \\ &= \frac{1}{2} (2 \mathbf{X}^T \mathbf{X} \mathbf{W} - \mathbf{X}^T \mathbf{y} - \mathbf{X}^T \mathbf{y}) \\ &= \mathbf{X}^T \mathbf{X} \mathbf{W} - \mathbf{X}^T \mathbf{y}\end{aligned}$$

向量求导规则可以参考:
<https://www.cnblogs.com/pinard/p/10773942.html>

最小二乘法的算法流程

- 之前得到

$$\begin{aligned}\frac{\partial L}{\partial \mathbf{W}} &= \frac{1}{2} \frac{\partial}{\partial \mathbf{W}} (\mathbf{W}^T X^T X \mathbf{W} - \mathbf{W}^T X^T \mathbf{y} - \mathbf{y}^T X \mathbf{W} + \mathbf{y}^T \mathbf{y}) \\ &= \frac{1}{2} (2X^T X \mathbf{W} - X^T \mathbf{y} - X^T \mathbf{y}) \\ &= X^T X \mathbf{W} - X^T \mathbf{y}\end{aligned}$$

- 令

$$X^T X \mathbf{W} - X^T \mathbf{y} = 0$$

可以得到 \mathbf{W} 的解析解：

$$\mathbf{W} = (X^T X)^{-1} X^T \mathbf{y}$$

最小二乘法的应用示例

- 单变量线性回归模型: $y = w \cdot x_t + b$
- 数据表示为:

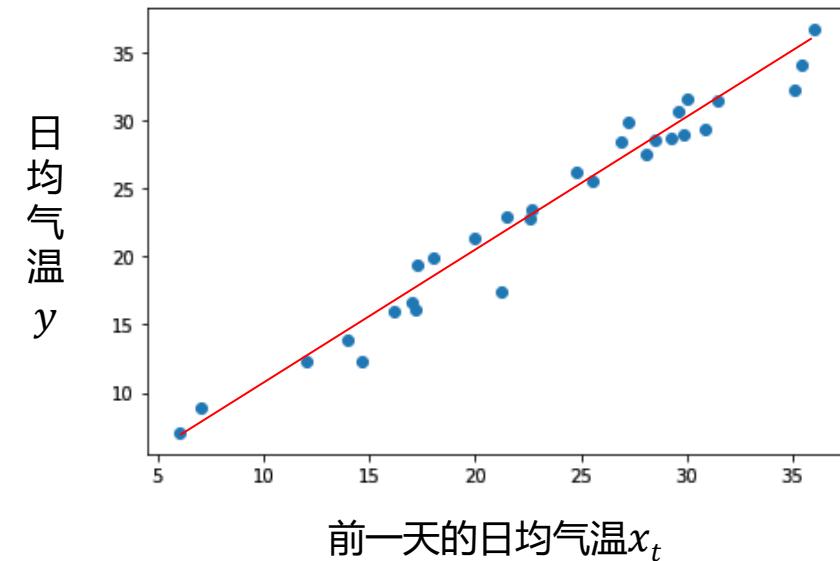
$$\mathbf{X} = \begin{pmatrix} 1 & x_{1,t} \\ 1 & x_{2,t} \\ \dots & \dots \\ 1 & x_{30,t} \end{pmatrix}$$

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_{30} \end{pmatrix}$$

$$\mathbf{w} = \begin{pmatrix} b \\ w \end{pmatrix}$$

- 可得

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} = \begin{pmatrix} 0.980 \\ 0.965 \end{pmatrix}$$



最小二乘法的问题

- 当这n个自变量不是互相独立，而是存在着一些线性关系时，此时 $X^T X$ 不可逆，此时得到的解为病态解，不能作为学习到的最优参数
- 当 $X^T X$ 不可逆时，可以采用梯度下降（Gradient Descent）方法求解